[учебный проект]

Определение стоимости автомобилей

1 Введение:

Сервис по продаже автомобилей с пробегом разрабатывает приложение для привлечения новых клиентов. В нём можно быстро узнать рыночную стоимость своего автомобиля. В вашем распоряжении исторические данные: технические характеристики, комплектации и цены автомобилей. Вам нужно построить модель для определения стоимости.

2 Цель проекта

Требуется построить модель машинного обучения для определения стоимости автомобиля.

3 Описание данных

Признаки

• DateCrawled — дата скачивания анкеты из базы

• VehicleType — тип автомобильного кузова

• RegistrationYear — год регистрации автомобиля

• Gearbox — тип коробки передач

• Power — мощность (л. с.)

• Model — модель автомобиля

• Kilometer — пробег (км)

• RegistrationMonth — месяц регистрации автомобиля

• FuelType — тип топлива

• Brand — марка автомобиля

• NotRepaired — была машина в ремонте или нет

• DateCreated — дата создания анкеты

• NumberOfPictures — количество фотографий автомобиля

• PostalCode — почтовый индекс владельца анкеты (пользователя)

• LastSeen — дата последней активности пользователя

Целевой признак

Price — цена (евро)

4 План работы

1. Загрузить и подготовить данные.

2. Обучить разные модели.

3. Проанализировать скорость работы и качество моделей.

5 Подготовка данных

Ввод [1]:

```
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.preprocessing import OrdinalEncoder
from sklearn.model_selection import train_test_split
from sklearn.model_selection import cross_val_score
from sklearn.metrics import make_scorer

from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import GridSearchCV

from sklearn.linear_model import LinearRegression
from sklearn.tree import DecisionTreeRegressor
from sklearn.ensemble import RandomForestRegressor
from sklearn.model_selection import RepeatedKFold
from lightgbm import LGBMRegressor

import lightgbm as lgb
```

```
C:\Users\Admin\.conda\envs\praktikum_env_win_new\lib\site-packages\statsmode
ls\tools\_testing.py:19: FutureWarning: pandas.util.testing is deprecated. U
se the functions in the public API at pandas.testing instead.
  import pandas.util.testing as tm
```

Ввод [2]:

```
df = pd.read_csv('autos.csv')
```

Ввод [3]:

```
# функция для изучения данных
def see(df):
    print(df.shape)
    print()
    print(df.columns)
    print()
    print(df.info())
    display(df.head())
    display(df.describe())
```

Ввод [4]:

```
1 see(df)
```

```
(354369, 16)

Index(['DateCrawled', 'Price', 'VehicleType', 'RegistrationYear', 'Gearbox',
       'Power', 'Model', 'Kilometer', 'RegistrationMonth', 'FuelType', 'Bran
d',
       'NotRepaired', 'DateCreated', 'NumberOfPictures', 'PostalCode',
       'LastSeen'],
      dtype='object')

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 354369 entries, 0 to 354368
Data columns (total 16 columns):
 #   Column             Non-Null Count   Dtype
---  ------             --------------   -----
 0   DateCrawled        354369 non-null  object
 1   Price              354369 non-null  int64
 2   VehicleType        316879 non-null  object
 3   RegistrationYear   354369 non-null  int64
 4   Gearbox            334536 non-null  object
 5   Power              354369 non-null  int64
 6   Model              334664 non-null  object
 7   Kilometer          354369 non-null  int64
 8   RegistrationMonth  354369 non-null  int64
 9   FuelType           321474 non-null  object
 10  Brand              354369 non-null  object
 11  NotRepaired        283215 non-null  object
 12  DateCreated        354369 non-null  object
 13  NumberOfPictures   354369 non-null  int64
 14  PostalCode         354369 non-null  int64
 15  LastSeen           354369 non-null  object
dtypes: int64(7), object(9)
memory usage: 43.3+ MB
None
```

	DateCrawled	Price	VehicleType	RegistrationYear	Gearbox	Power	Model	Kilometer	Regi
0	2016-03-24 11:52:17	480	NaN	1993	manual	0	golf	150000	
1	2016-03-24 10:58:45	18300	coupe	2011	manual	190	NaN	125000	
2	2016-03-14 12:52:21	9800	suv	2004	auto	163	grand	125000	
3	2016-03-17 16:54:04	1500	small	2001	manual	75	golf	150000	
4	2016-03-31 17:25:20	3600	small	2008	manual	69	fabia	90000	

	Price	RegistrationYear	Power	Kilometer	RegistrationMonth	Numb
count	354369.000000	354369.000000	354369.000000	354369.000000	354369.000000	
mean	4416.656776	2004.234448	110.094337	128211.172535	5.714645	
std	4514.158514	90.227958	189.850405	37905.341530	3.726421	
min	0.000000	1000.000000	0.000000	5000.000000	0.000000	
25%	1050.000000	1999.000000	69.000000	125000.000000	3.000000	
50%	2700.000000	2003.000000	105.000000	150000.000000	6.000000	
75%	6400.000000	2008.000000	143.000000	150000.000000	9.000000	
max	20000.000000	9999.000000	20000.000000	150000.000000	12.000000	

Выводы:

Колонка RegistrationYear: есть аномальные значения (min = 1000 или max = 9999 это когда?)

Колонка Power: есть аномальные значения (max = 20000 л.с. - это ракета, будем счиать её выбросом)

Пропуски в колонках: VehicleType, Gearbox, Model, FuelType, NotRepaired.

Аномалии исключим, пропуски возможно тоже, но это не точно. сначала посмотрим на графики этих фичей.

Ввод [6]:

```
df['RegistrationYear'].hist(bins=100)
plt.title('Визуальная проверка аномалии')
plt.xlabel('Год регистрации автомобиля')
plt.ylabel('Количество записей в таблице');
```

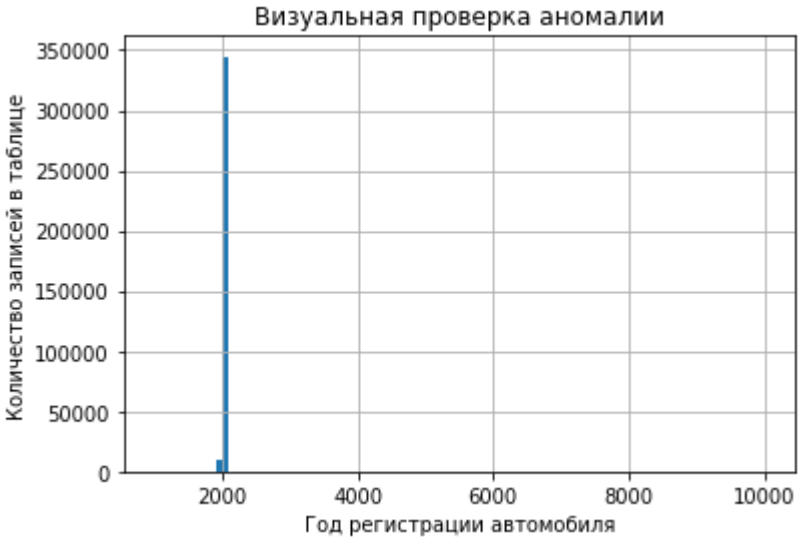

Ввод [7]:

```
df['RegistrationYear'].hist(bins=100, range=(1955, 2030), figsize=(10, 5))
plt.title('Проверка настроенного фильтра')
plt.xlabel('Год регистрации автомобиля')
plt.ylabel('Количество записей в таблице');
```

Ввод [8]:

```
df = df[(df['RegistrationYear']>1955) & (df['RegistrationYear']<2030)]
```

Ввод [9]:

```
df['RegistrationYear'].describe()
```

Out[9]:

```
count    353939.00000
mean       2003.13762
std           7.26471
min        1956.00000
25%        1999.00000
50%        2003.00000
75%        2008.00000
max        2019.00000
Name: RegistrationYear, dtype: float64
```

Выводы:

Аномалии по году регистрации (RegistrationYear) удалены

Удалим аномалии по полю Мощность (Power)

Ввод [10]:

```
df['Power'].hist(bins=100)
plt.title('Визуальная проверка аномалии')
plt.xlabel('Мощность (л. с.)')
plt.ylabel('Количество записей в таблице');
```

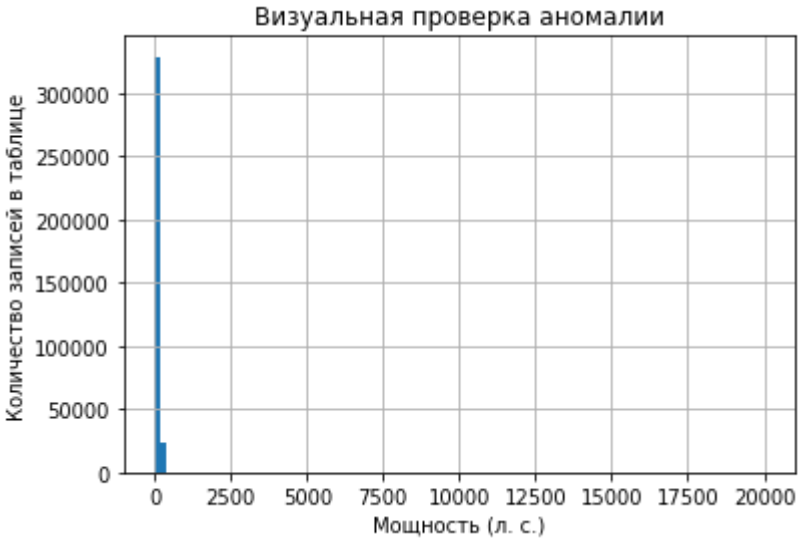

Ввод [11]:

```
df['Power'].hist(bins=100, range=(0, 800), figsize=(10, 5));
plt.title('Проверка настроенного фильтра')
plt.xlabel('Мощность (л. с.)')
plt.ylabel('Количество записей в таблице');
```

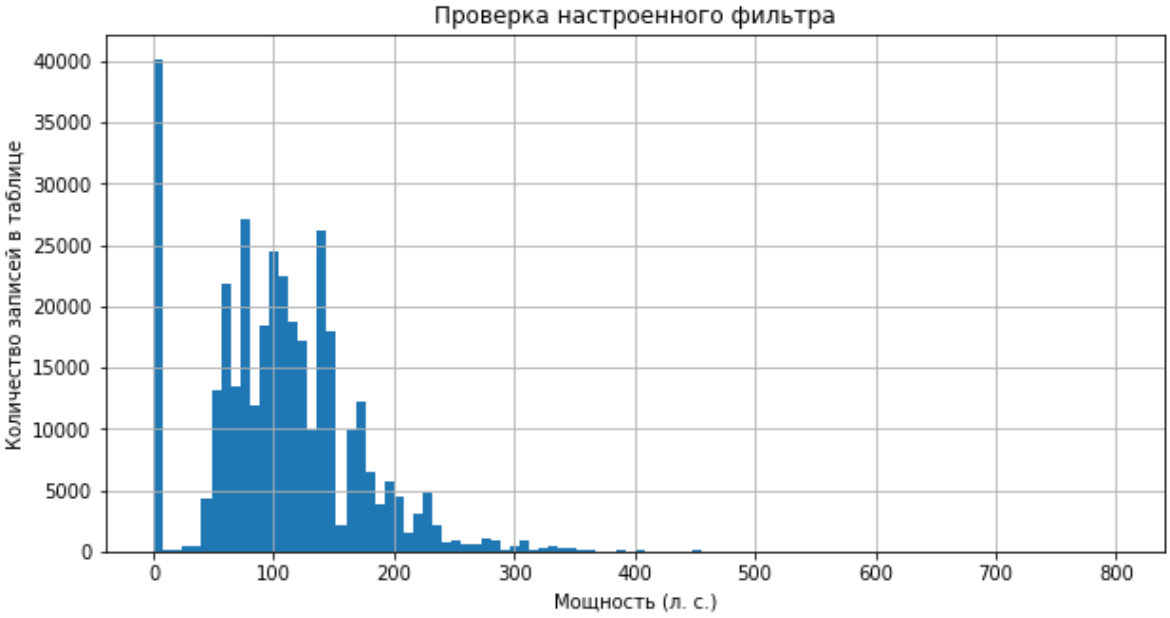

Ввод [12]:

```
plt.figure(figsize=(10,5))
plt.ylim(0, 330)
sns.boxplot(x='VehicleType', y='Power', data=df)
plt.title('Анализ зависимости типа кузова от мощности автомобиля')
plt.xlabel('тип автомобильного кузова')
plt.ylabel('Мощность (л. с.)');
```

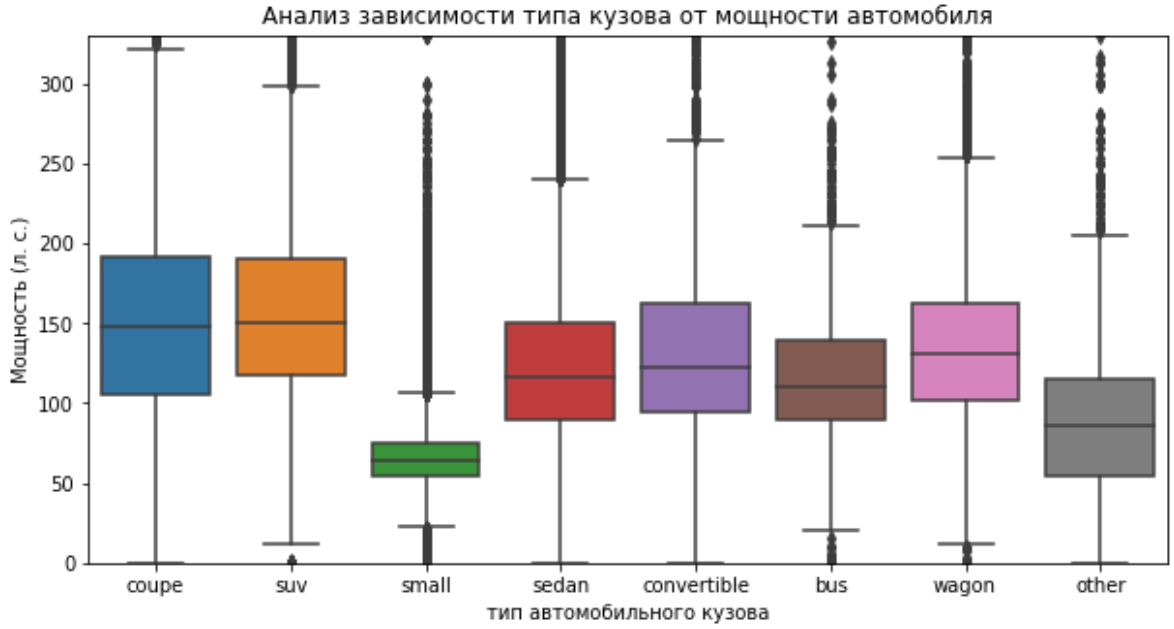

Ввод [13]:

```
df[df['Power']>330]['Power'].count()/len(df)
```

Out[13]:

```
0.005707198133011621
```

Ввод [14]:

```
df = df[df['Power']<330]
```

Выводы:

Аномалии по полю Мощность (Power) удалены

Заполним пропуски в колонках: VehicleType, Gearbox, Model, FuelType, NotRepaired.

За данные о названии модели автомобиля, типе коробки передач и типе кузова бороться не будем, т.к. велика вероятность ошибки.

Просто удалим их из выборки.

Ввод [15]:

```
df.shape
```

Out[15]:

```
(351869, 16)
```

Ввод [16]:

```
df = df.dropna(subset = ['Model'])
```

Ввод [17]:

```
df.shape
```

Out[17]:

```
(332584, 16)
```

Ввод [18]:

```
# создадим справочник, по которому можно подобрать тип топлива
df_bm = df.groupby(['Brand','Model','Gearbox','VehicleType'])['Price'].count().reset_ir
df_bm['BM'] = df_bm['Brand']+df_bm['Model']
df_bm = df_bm.drop(['Price', 'Brand', 'Model'], axis=1)
# справочники для склеивания
df_bm_v = df_bm.drop(['Gearbox'], axis=1).drop_duplicates('BM').reset_index(drop=True)
df_bm_g = df_bm.drop(['VehicleType'], axis=1).drop_duplicates('BM').reset_index(drop=Tr
```

Ввод [19]:

```
df_v0 = df[df['VehicleType'].isna()].drop(['VehicleType'], axis=1) # пропуски
df_v0['BM'] = df_v0['Brand']+df_v0['Model'] # пропуски

df_v2 = df[~df['VehicleType'].isna()] # без пропусков
df_tmpv = df_v0.merge(df_bm_v, how = 'left', on='BM').drop(['BM'], axis=1)
# так мы заполнили 'VehicleType'
df = pd.concat([df_v2, df_tmpv])
```

Ввод [20]:

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 332584 entries, 2 to 30426
Data columns (total 16 columns):
 #   Column             Non-Null Count   Dtype 
---  ------             --------------   ----- 
 0   DateCrawled        332584 non-null  object
 1   Price              332584 non-null  int64 
 2   VehicleType        332584 non-null  object
 3   RegistrationYear   332584 non-null  int64 
 4   Gearbox            317026 non-null  object
 5   Power              332584 non-null  int64 
 6   Model              332584 non-null  object
 7   Kilometer          332584 non-null  int64 
 8   RegistrationMonth  332584 non-null  int64 
 9   FuelType           307099 non-null  object
 10  Brand              332584 non-null  object
 11  NotRepaired        270949 non-null  object
 12  DateCreated        332584 non-null  object
 13  NumberOfPictures   332584 non-null  int64 
 14  PostalCode         332584 non-null  int64 
 15  LastSeen           332584 non-null  object
dtypes: int64(7), object(9)
memory usage: 43.1+ MB
```

Ввод [21]:

```
df_g0 = df[df['Gearbox'].isna()].drop(['Gearbox'], axis=1) # пропуски
df_g0['BM'] = df_g0['Brand']+df_g0['Model'] # пропуски

df_g2 = df[~df['Gearbox'].isna()] # без пропусков
df_tmpg = df_g0.merge(df_bm_g, how = 'left', on='BM').drop(['BM'], axis=1)
# так мы заполнили 'Gearbox'
df = pd.concat([df_g2, df_tmpg])
```

Ввод [22]:

```
1  df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 332584 entries, 2 to 15557
Data columns (total 16 columns):
 #   Column             Non-Null Count   Dtype
---  ------             --------------   -----
 0   DateCrawled        332584 non-null  object
 1   Price              332584 non-null  int64
 2   VehicleType        332584 non-null  object
 3   RegistrationYear   332584 non-null  int64
 4   Gearbox            332584 non-null  object
 5   Power              332584 non-null  int64
 6   Model              332584 non-null  object
 7   Kilometer          332584 non-null  int64
 8   RegistrationMonth  332584 non-null  int64
 9   FuelType           307099 non-null  object
 10  Brand              332584 non-null  object
 11  NotRepaired        270949 non-null  object
 12  DateCreated        332584 non-null  object
 13  NumberOfPictures   332584 non-null  int64
 14  PostalCode         332584 non-null  int64
 15  LastSeen           332584 non-null  object
dtypes: int64(7), object(9)
memory usage: 43.1+ MB
```

5.1 Заполнение пропущенных значений для FuelType

Ввод [23]:

```
1  #Объединим бензин из UK и USA
2  df.loc[(df.FuelType == 'petrol'), 'FuelType'] = 'gasoline'
3  df['FuelType'].value_counts()
```

Out[23]:

```
gasoline    301344
lpg           4814
cng            541
hybrid         207
other          129
electric        64
Name: FuelType, dtype: int64
```

Ввод [24]:

```
# создадим справочник, по которому можно подобрать тип топлива
df_fuel = df.groupby(['Brand','Model','Gearbox','VehicleType','FuelType'])['Price'].cou
df_fuel = df_fuel.rename(columns = {'Price': 'Moda'}, inplace = False)
df_fuel.head(3)
```

Out[24]:

	Brand	Model	Gearbox	VehicleType	FuelType	Moda
0	alfa_romeo	145	manual	coupe	gasoline	11
1	alfa_romeo	145	manual	other	gasoline	1
2	alfa_romeo	145	manual	sedan	gasoline	13

Ввод [25]:

```
df_fuel.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 3208 entries, 0 to 3207
Data columns (total 6 columns):
 #   Column       Non-Null Count  Dtype 
---  ------       --------------  ----- 
 0   Brand        3208 non-null   object
 1   Model        3208 non-null   object
 2   Gearbox      3208 non-null   object
 3   VehicleType  3208 non-null   object
 4   FuelType     3208 non-null   object
 5   Moda         3208 non-null   int64 
dtypes: int64(1), object(5)
memory usage: 150.5+ KB
```

Ввод [26]:

```
# выделим таблицу с незвестным видом топлива
df0 = df[df['FuelType'].isna()]
df0 = df0.drop(['FuelType'], axis=1)
# 'BMGV' - это ключ, по которому будет выполненно совмещение таблиц (выбор по справочни
df0['BMGV'] = df0['Brand']+df0['Model']+df0['Gearbox']+df0['VehicleType']
df0.shape
```

Out[26]:

```
(25485, 16)
```

Ввод [27]:

```
# упростим справочник (оставим только ключ и таргет)
df_fuel['BMGV'] = df_fuel['Brand'] + df_fuel['Model'] + df_fuel['Gearbox'] + df_fuel['\
df_fuel = pd.DataFrame(df_fuel, columns=['BMGV','FuelType'])
```

Ввод [28]:

```
# процедура выбора типа топлива по справочнику
df0 = df0.merge(df_fuel, on='BMGV', how='inner')
df0 = df0.drop(['BMGV'], axis=1)
df0.shape
```

Out[28]:

```
(66183, 16)
```

Ввод [29]:

```
df0.head(3)
```

Out[29]:

	DateCrawled	Price	VehicleType	RegistrationYear	Gearbox	Power	Model	Kilometer	Regis
0	2016-03-17 10:53:50	999	small	1998	manual	101	golf	150000	
1	2016-03-17 10:53:50	999	small	1998	manual	101	golf	150000	
2	2016-03-17 10:53:50	999	small	1998	manual	101	golf	150000	

Ввод [30]:

```
# исключим из основной таблицы строки с неизвестным типом топлива
df = df[~df['FuelType'].isna()]
```

Ввод [31]:

```
df = pd.concat([df,df0], sort=False, axis=0).reset_index(drop=True)
# данные о типе топлива востановлены
```

Ввод [32]:

```
df['NotRepaired'] = df['NotRepaired'].fillna('?')
```

Ввод [33]:

```
1 df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 373282 entries, 0 to 373281
Data columns (total 16 columns):
 #   Column             Non-Null Count   Dtype 
---  ------             --------------   ----- 
 0   DateCrawled        373282 non-null  object
 1   Price              373282 non-null  int64 
 2   VehicleType        373282 non-null  object
 3   RegistrationYear   373282 non-null  int64 
 4   Gearbox            373282 non-null  object
 5   Power              373282 non-null  int64 
 6   Model              373282 non-null  object
 7   Kilometer          373282 non-null  int64 
 8   RegistrationMonth  373282 non-null  int64 
 9   FuelType           373282 non-null  object
 10  Brand              373282 non-null  object
 11  NotRepaired        373282 non-null  object
 12  DateCreated        373282 non-null  object
 13  NumberOfPictures   373282 non-null  int64 
 14  PostalCode         373282 non-null  int64 
 15  LastSeen           373282 non-null  object
dtypes: int64(7), object(9)
memory usage: 45.6+ MB
```

Выводы:

Данные готовы к работе

Ввод [34]:

```
1 df['Price'].describe()
```

Out[34]:

```
count    373282.000000
mean       4228.332542
std        4415.470195
min           0.000000
25%        1000.000000
50%        2500.000000
75%        5999.000000
max       20000.000000
Name: Price, dtype: float64
```

Ввод [36]:

```
df[df['Price']<200]['Price'].hist()
plt.title('Автомобили с ценой ниже 200 евро')
plt.xlabel('Цена (евро)')
plt.ylabel('Количество записей в таблице');
```

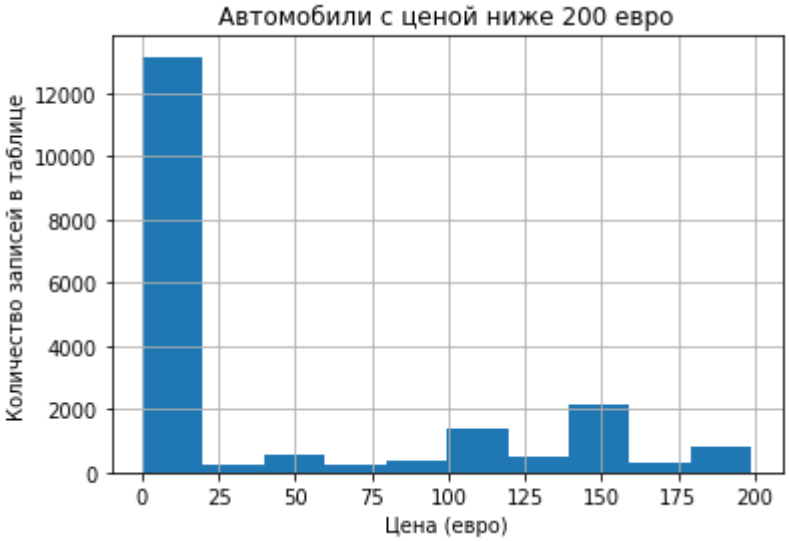

Ввод [37]:

```
df[df['Price'] < 100]['Price'].count()
```

Out[37]:

14564

Ввод [38]:

```
plt.xlim(-200, 14000)
sns.boxplot(df['Price'])
plt.title('Диаграмма размаха для признака Price');
```

Ввод [39]:

```
df = df[(df['Price'] > 100)&(~df['Price'].isna())]
df = df.dropna().reset_index(drop=True)
```

Ввод [40]:

```
df['Price'].describe()
```

Out[40]:

```
count    357408.000000
mean       4415.516315
std        4420.217824
min         101.000000
25%        1190.000000
50%        2750.000000
75%        6290.000000
max       20000.000000
Name: Price, dtype: float64
```

Ввод [41]:

```
df = df.drop(['DateCrawled','RegistrationMonth',
              'DateCreated','NumberOfPictures',
              'PostalCode','LastSeen'], axis=1)
```

Ввод [42]:

```
sns.set_style('whitegrid')
df_vehicletype = (df.pivot_table(index='VehicleType', values='Price', aggfunc='mean')
                  .sort_values('Price',ascending=False)
                  .reset_index())
plt.figure(figsize=(10,5))
sns.barplot(x='VehicleType', y='Price', data=df_vehicletype);

plt.title('Зависимость цены от типа автомобильного кузова');
plt.xlabel('Тип автомобильного кузова')
plt.ylabel('Ср.цена (евро)');
```

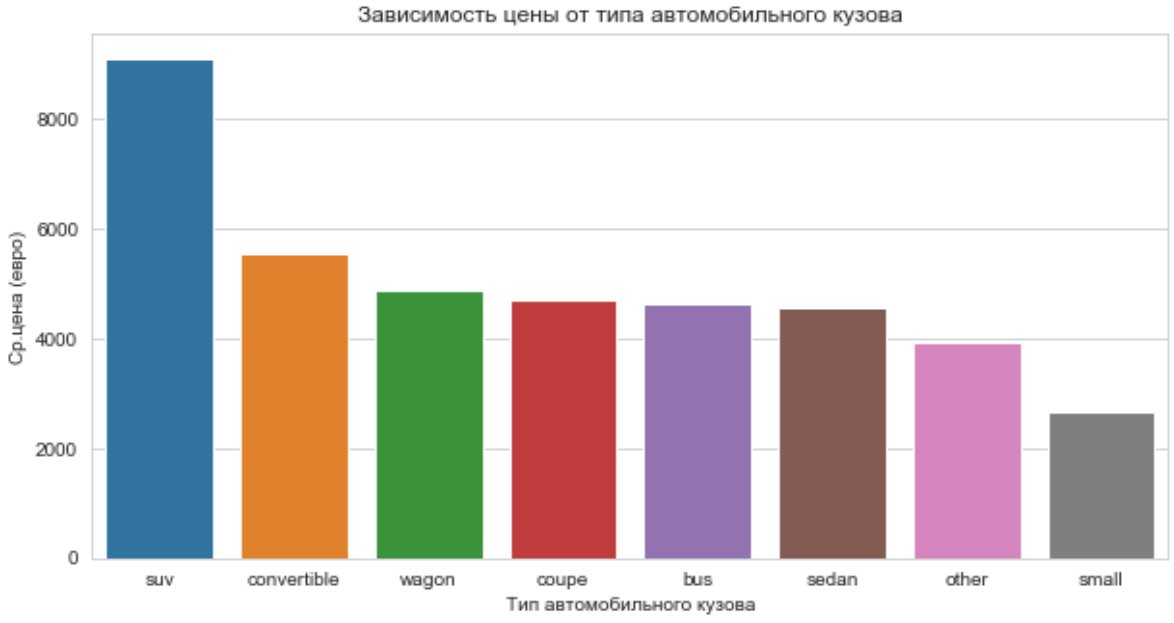

Ввод [43]:

```
(
df.pivot_table(index='Brand', values='Price', aggfunc='median')
.sort_values('Price',ascending=False).plot(grid=True, kind='bar', figsize=(10, 5))
);

plt.title('Зависимость цены от брэнда')
plt.xlabel('Брэнд автомобиля')
plt.ylabel('Цена (евро)');
```

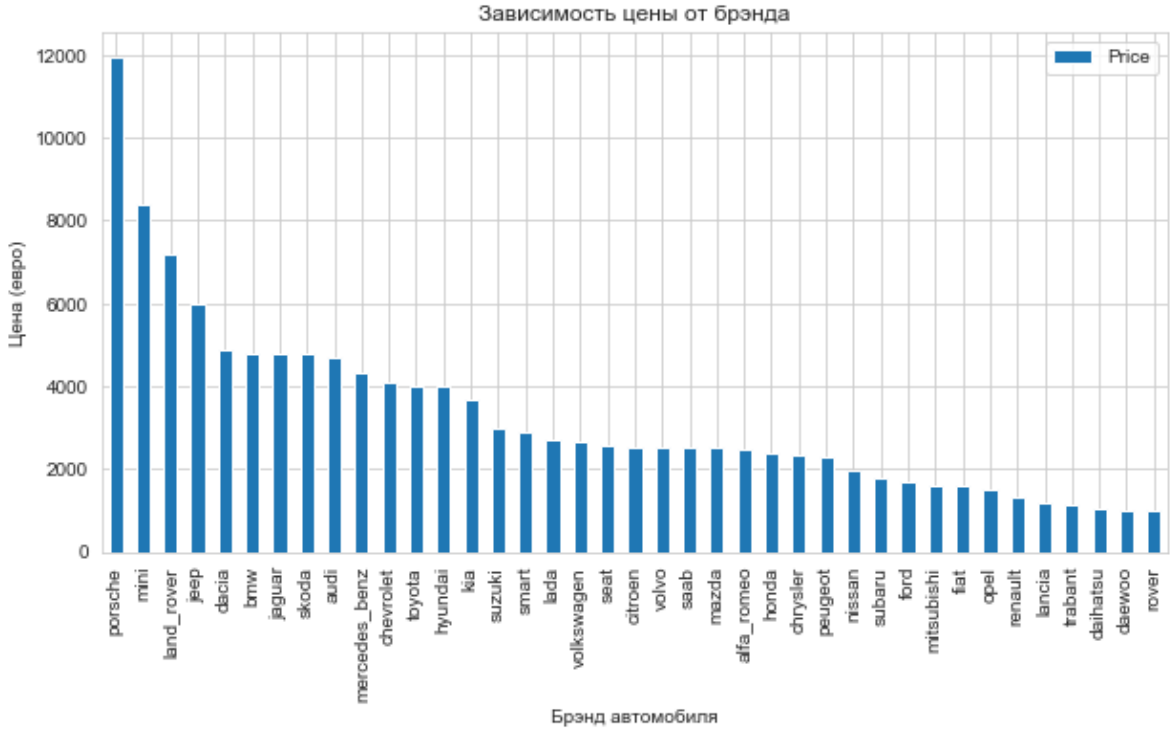

Ввод [44]:

```
1  Gearbox = df['Gearbox'].value_counts(normalize=True)
2  print(Gearbox)
3  Gearbox.plot(kind='bar');
4  plt.legend(loc='best');
5
6  plt.title('Сравнение авто по типу коробки передач')
7  plt.xlabel('Тип коробки передач')
8  plt.ylabel('Доля ед.');
```

```
manual    0.77207
auto      0.22793
Name: Gearbox, dtype: float64
```

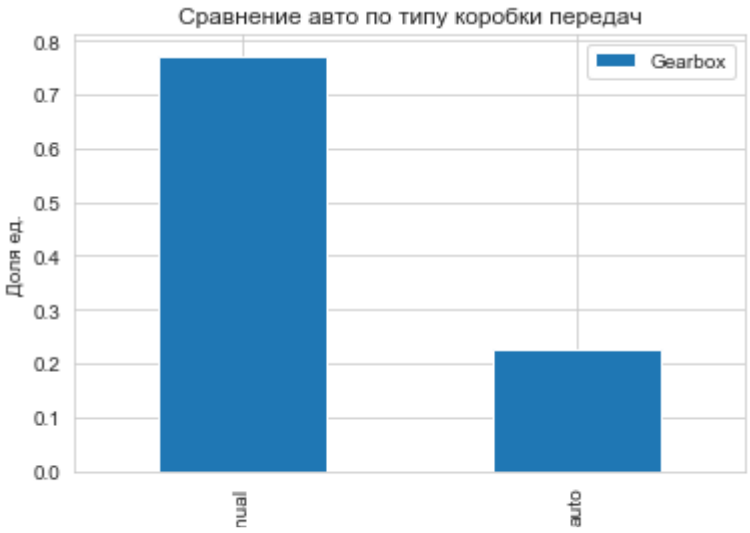

Ввод [45]:

```
Gearbox = df['NotRepaired'].value_counts(normalize=True)
print(Gearbox)
Gearbox.plot(kind='bar');
plt.legend(loc='best');

plt.title('Соотношение авто без ремонта и с ремонтом')
plt.xlabel('Авто без ремонта')
plt.ylabel('Доля ед.');
```

```
no     0.700757
?      0.200065
yes    0.099178
Name: NotRepaired, dtype: float64
```

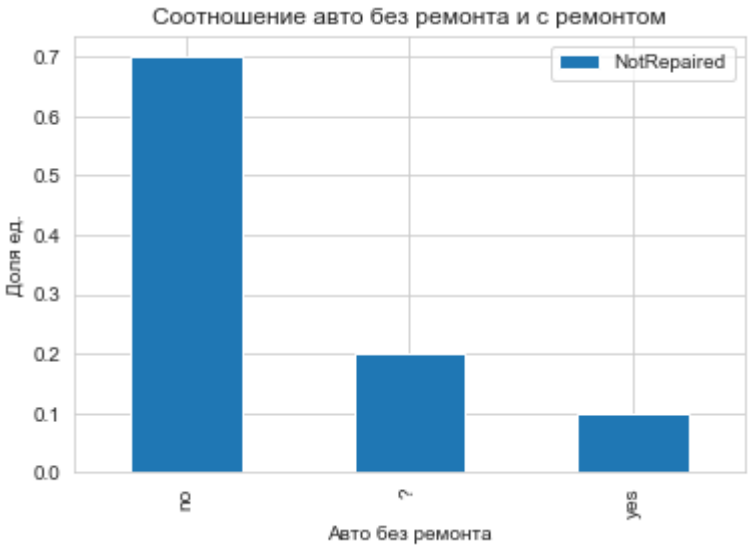

Ввод [46]:

```
plt.figure(figsize=(10,5))
sns.lineplot(data=df, x="Power", y="Price")

plt.title('Зависимость цены от мощности двигателя');
plt.xlabel('Можность (л.с.)')
plt.ylabel('Ср.цена (евро)');
```

Выводы:

Из графиков стало понятно как цена зависит от количества лошадинных сил, какие бренды автомобилей дороже остальных и что 80% водителей предпочитают коробку автомат.

В базе нашего магазна всего 10% не битых и не крашенных автомобилей.

6 Обучение моделей

Ввод [47]:

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 357408 entries, 0 to 357407
Data columns (total 10 columns):
 #   Column            Non-Null Count   Dtype 
---  ------            --------------   ----- 
 0   Price             357408 non-null  int64 
 1   VehicleType       357408 non-null  object
 2   RegistrationYear  357408 non-null  int64 
 3   Gearbox           357408 non-null  object
 4   Power             357408 non-null  int64 
 5   Model             357408 non-null  object
 6   Kilometer         357408 non-null  int64 
 7   FuelType          357408 non-null  object
 8   Brand             357408 non-null  object
 9   NotRepaired       357408 non-null  object
dtypes: int64(4), object(6)
memory usage: 27.3+ MB
```

Ввод [48]:

```
# Выделим числовые и категориальные признаки:
categorical_columns = [c for c in df.columns if df[c].dtype.name == 'object']
numerical_columns   = [c for c in df.columns if df[c].dtype.name != 'object']
print(categorical_columns)
print(numerical_columns)
```

```
['VehicleType', 'Gearbox', 'Model', 'FuelType', 'Brand', 'NotRepaired']
['Price', 'RegistrationYear', 'Power', 'Kilometer']
```

Ввод [49]:

```
df01 = df[categorical_columns]
df02 = df[numerical_columns]
# для категориальных признаков применим порядковое кодирование
encoder = OrdinalEncoder()
data_ordinal = pd.DataFrame(encoder.fit_transform(df01), columns=categorical_columns)
data_ordinal.head(3)
```

Out[49]:

	VehicleType	Gearbox	Model	FuelType	Brand	NotRepaired
0	6.0	0.0	117.0	2.0	14.0	0.0
1	5.0	1.0	116.0	2.0	37.0	1.0
2	5.0	1.0	101.0	2.0	31.0	1.0

Ввод [50]:

```
df = data_ordinal.join(df02)
df.shape
```

Out[50]:

```
(357408, 10)
```

Ввод [51]:

```
df.head(3)
```

Out[51]:

	VehicleType	Gearbox	Model	FuelType	Brand	NotRepaired	Price	RegistrationYear	Powe
0	6.0	0.0	117.0	2.0	14.0	0.0	9800	2004	163
1	5.0	1.0	116.0	2.0	37.0	1.0	1500	2001	75
2	5.0	1.0	101.0	2.0	31.0	1.0	3600	2008	69

Ввод [52]:

```
target = df['Price']
features = df.drop(['Price'] , axis=1)
features_train, features_valid, target_train, target_valid = train_test_split(
    features, target, test_size=0.25, random_state=12345)
```

Ввод [53]:

```
# смасштабируем данные
scaler = StandardScaler()
scaler.fit(features_train)
features_train = scaler.transform(features_train)
features_valid = scaler.transform(features_valid)
```

Ввод [54]:

```
# функция метрики
def rmse(targets, predictions):
    differences = predictions - targets
    differences_squared = differences ** 2
    mean_of_differences_squared = differences_squared.mean()
    rmse_val = np.sqrt(mean_of_differences_squared)
    return rmse_val
```

Ввод [55]:

```
%%time
model1 = LinearRegression()
model1.fit(features_train, target_train)
predicted_valid = model1.predict(features_valid)
rmse1 = rmse(target_valid, predicted_valid)

print('RMSE LinearRegression =', rmse1 )
```

```
RMSE LinearRegression = 3223.021392413865
Wall time: 113 ms
```

Ввод [56]:

```
rmse_score = make_scorer(rmse, greater_is_better = False)
```

Ввод [57]:

```
%%time
model3 = DecisionTreeRegressor(random_state=12345)
param = {'max_depth': range(1,5,1),
        'min_samples_leaf':range(1,6),
        'min_samples_split':range(2,4)}
grid = GridSearchCV(model3, param, cv=5, scoring=rmse_score)
grid.fit(features_train, target_train)
param = grid.best_params_

model3.fit(features_train, target_train)
predicted_valid = model3.predict(features_valid)
rmse3 = rmse(target_valid, predicted_valid)

print('RMSE DecisionTreeRegressor =', rmse3)
```

```
RMSE DecisionTreeRegressor = 1848.660145493719
Wall time: 36.8 s
```

Ввод [58]:

```
%%time
for depth in range(1, 10, 1):
    model2 = RandomForestRegressor(n_estimators=20, max_depth=depth, random_state=1234
    model2.fit(features_train, target_train)
    predicted_valid = model2.predict(features_valid)
rmse2 = rmse(target_valid, predicted_valid)
#scores = cross_val_score(model2, features_train, target_train, scoring=rmse, cv=5)
print('RMSE RandomForestRegressor =', rmse2 )
```

```
RMSE RandomForestRegressor = 1965.2847151525846
Wall time: 44.6 s
```

Ввод [59]:

```
# теперь попробуем бустингом
print("Версия LightGBM      : ", lgb.__version__)
```

```
Версия LightGBM      :  3.2.1
```

Ввод [60]:

```
%%time
model4 = LGBMRegressor()
cv = RepeatedKFold(n_splits=10, n_repeats=3, random_state=12345)
n_scores = cross_val_score(model4, features_train, target_train, scoring=rmse_score, cv

model4.fit(features_train, target_train)
predicted_valid = model4.predict(features_valid)
rmse4 = rmse(target_valid, predicted_valid)

print('RMSE LGBMRegressor =', rmse4)
```

```
RMSE LGBMRegressor = 1723.9286646829898
Wall time: 40.8 s
```

7 Анализ моделей

Выводы:

В ходе исследования были рассмотрены 4 ML модели:

RMSE LinearRegression = 3223.021392413865 | Wall time: 113 ms

RMSE DecisionTreeRegressor = 1848.660145493719 | Wall time: 36.8 s

RMSE RandomForestRegressor = 1965.2847151525846 | Wall time: 44.6 s

RMSE LGBMRegressor = 1723.9286646829898 | Wall time: 40.8 s

Линейная регрессия выделяется как своей быстротой, так и низкой точностью. Не удовлетворяет условию задачи.

Дерево решений удовлетворяет условиям задачи за приемлемое время

Случайный лес немного точнее и чуть медленее дерева решений

LGBMR от Майкрософт показал похожее время и лучшее качество (рекомендован к внедрению).